ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
VNUHCM - UIT

XÂY DỰNG, TIỀN XỬ LÝ BỘ DỮ LIỆU BÌNH LUẬN MẠNG XÃ HỘI VÀ THỰC NGHIỆM HỆ THỐNG PHÂN LOẠI PHÂN CẤP PHÁT NGÔN ĐỘC HẠI TIẾNG VIỆT

BÁO CÁO ĐỒ ÁN CUỐI KỲ MÔN: THU THẬP VÀ TIỀN XỬ LÝ DỮ LIỆU
DS108.Q21.LT

Giảng viên hướng dẫn: TS. Lưu Thanh Sơn

Nhóm sinh viên thực hiện: Dương Tùng Dương - 25550006
Nguyễn Hoàng Phúc - 25550018

NỘI DUNG ĐỀ TÀI

1 GIỚI THIỆU

2 BỘ DỮ LIỆU

3 THỰC NGHIỆM & MÔ HÌNH

4 HẠN CHẾ, HƯỚNG PHÁT TRIỂN

1 Giới thiệu

1 .1 Giới thiệu sơ lược

- Bùng nổ không gian số tại Việt Nam:
  + 76,2 triệu tài khoản người dùng mạng xã hội, chiếm 75,2% tổng dân số (Báo cáo Digital 2025: Vietnam).

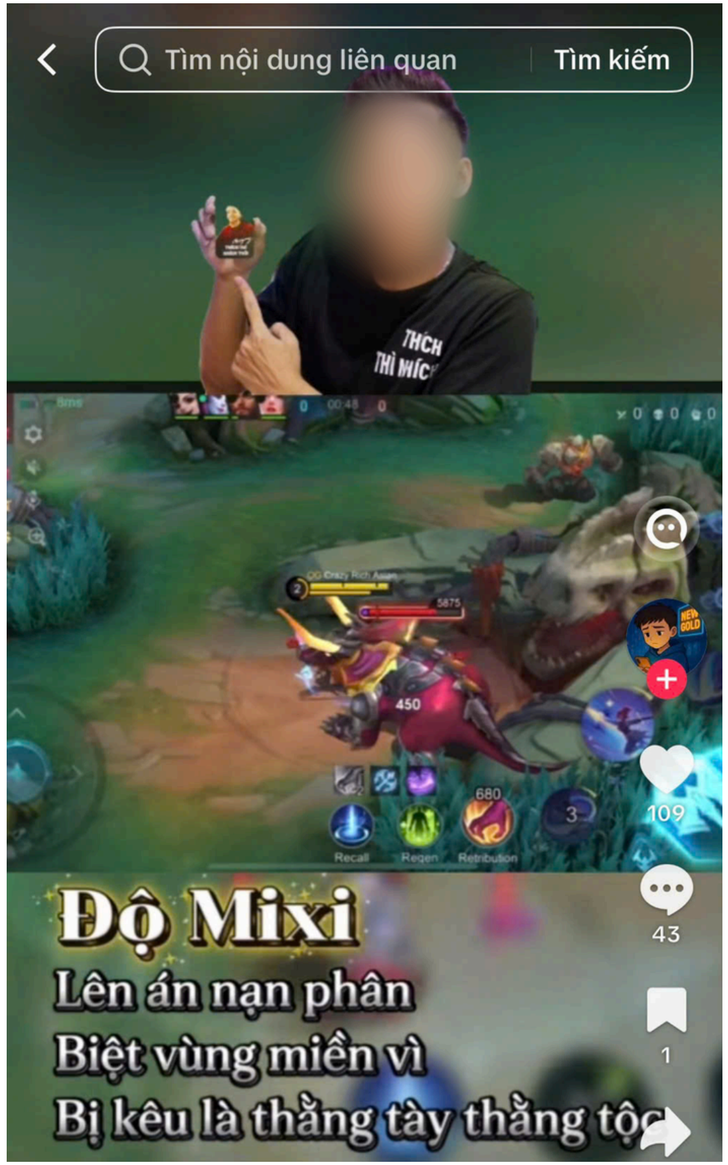
- Thực trạng & Hệ lụy của Ngôn từ Độc hại:
- Việt Nam nằm trong nhóm 5 quốc gia có chỉ số văn minh trực tuyến thấp nhất thế giới (Microsoft DCI).

- Lan tràn các hành vi: công kích cá nhân, xúc phạm ngoại hình, miệt thị vùng miền, kỳ thị giới tính và tôn giáo.

- Ba hệ lụy sâu sắc: Xói mòn môi trường thảo luận văn minh → Tổn thương tâm lý nghiêm trọng →Định kiến xã hội.

1 Giới thiệu

1.2 Ví dụ



tính ra nó nói có sai đâu, giờ trên mạng gặp nhiều đứa coi chuyện pbvm là bình thường 🙄🙄

2025-12-23 Trả lời

Thì nó gọi đúng còn gì thì ko gọi độ tày ah 🤣🤣

2025-12-25 Trả lời

Nó kêu gái cà màu sao nó ko nói 😄😄😄

2025-12-15 Trả lời 2

Xem 2 câu trả lời

lộn đồ 🥰

2025-12-15 Trả lời 4

Xem 2 câu trả lời

Thôn hoá lành 😂

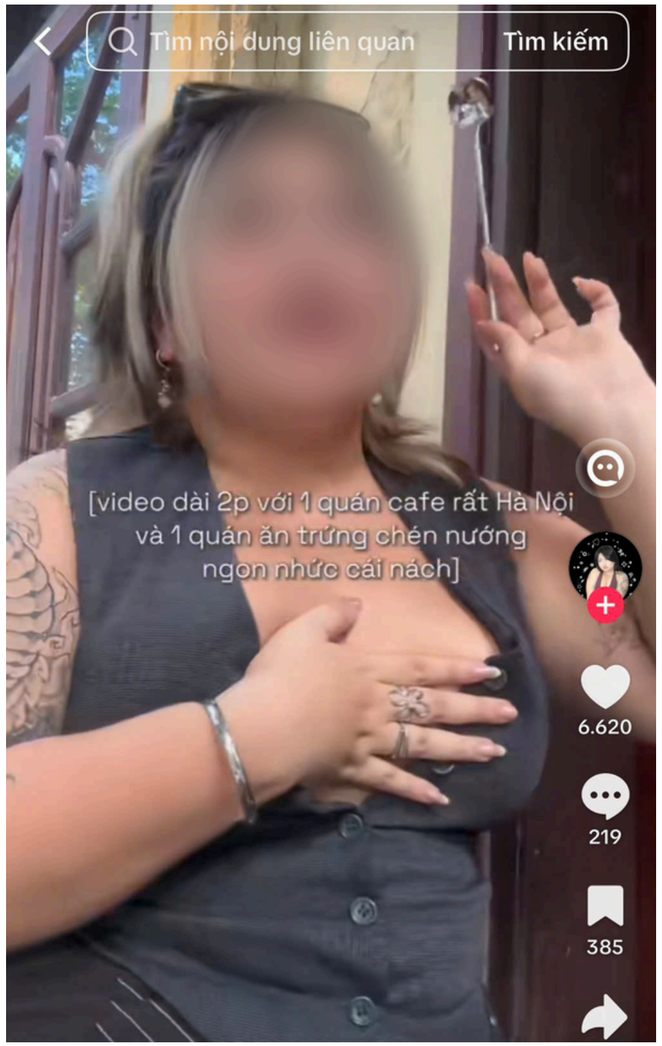
1-6 Trả lời

ai mượn ăn rau má phá đường tàu cơ😂

2021-8-25 Trả lời 170

1 Giới thiệu

1.2 Ví dụ



Béooooo vaiz chuppy số 1 vn

2025-11-16 Trả lời

Chuppy ❌
Grakk ✅

2025-6-17 Trả lời 82

Xem 10 câu trả lời

sợ ghế gãy:)

2025-6-14 Trả lời 102

Xem 5 câu trả lời

Cổ đẹp theo 1 cách lạ , lạ 1 tợn☺️

2025-6-14 Trả lời 8.023

Xem 58 câu trả lời

2 Bộ dữ liệu

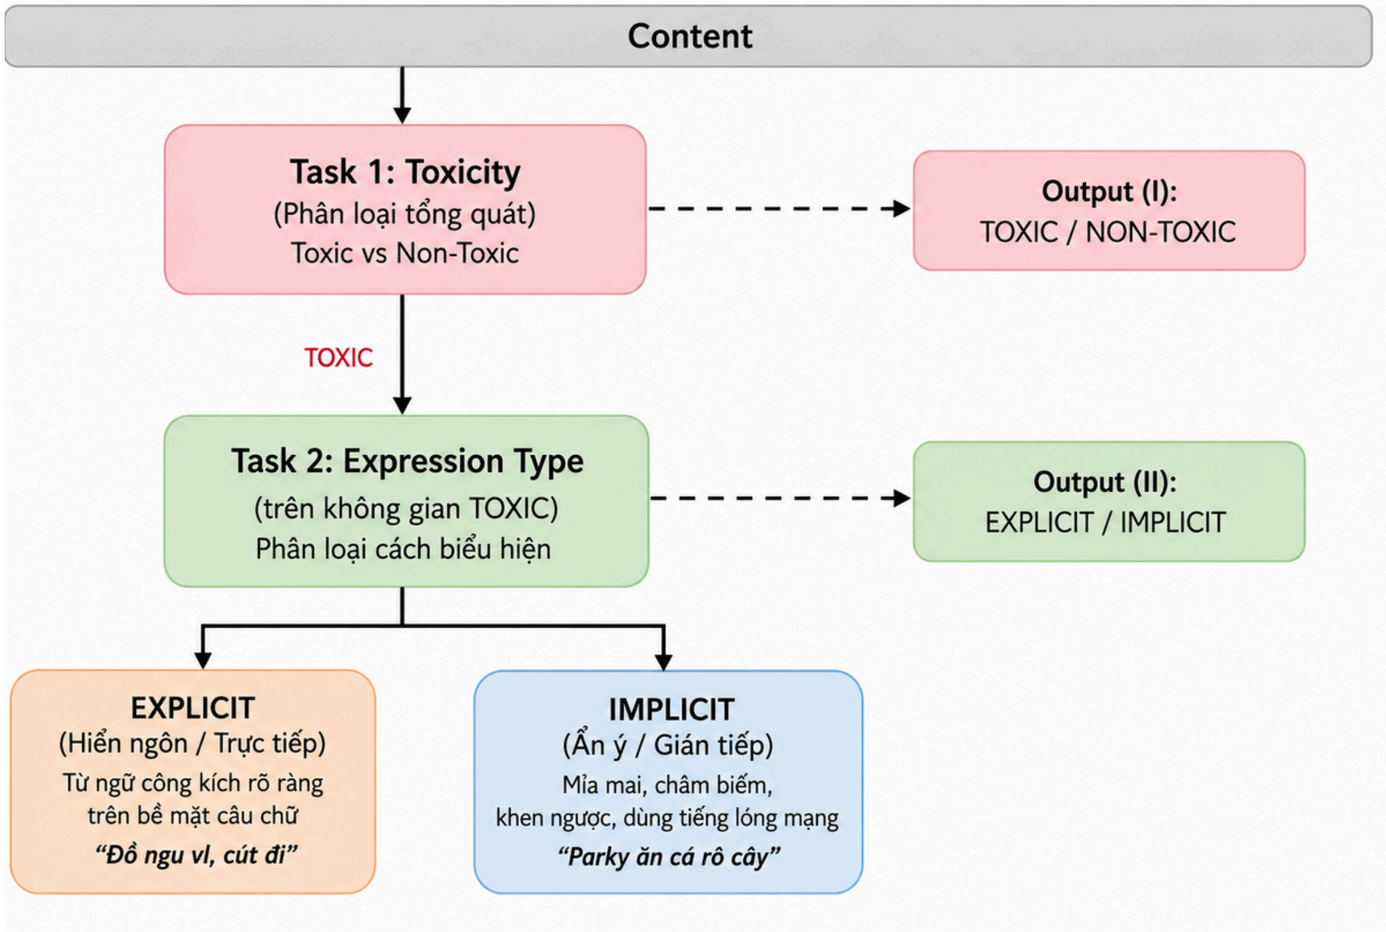
Cấu trúc phân tầng hai tác vụ độc lập:

Tác vụ 1 (Toxicity): Phân loại tổng quát giữa TOXIC (Độc hại) và NON-TOXIC (Bình thường / Lành mạnh).

Tác vụ 2 (Expression Type trên không gian TOXIC):

EXPLICIT (Trực tiếp): Từ ngữ công kích rõ ràng trên bề mặt câu chữ ("Đồ ngu vl, cút đi").

IMPLICIT (Ẩn ý / Gián tiếp): Mỉa mai, châm biếm, khen ngược, dùng tiếng lóng mạng ("Parky ăn cá rô cây", "Trình độ đỉnh vl, lần nào làm cũng phá").



2 Bộ dữ liệu

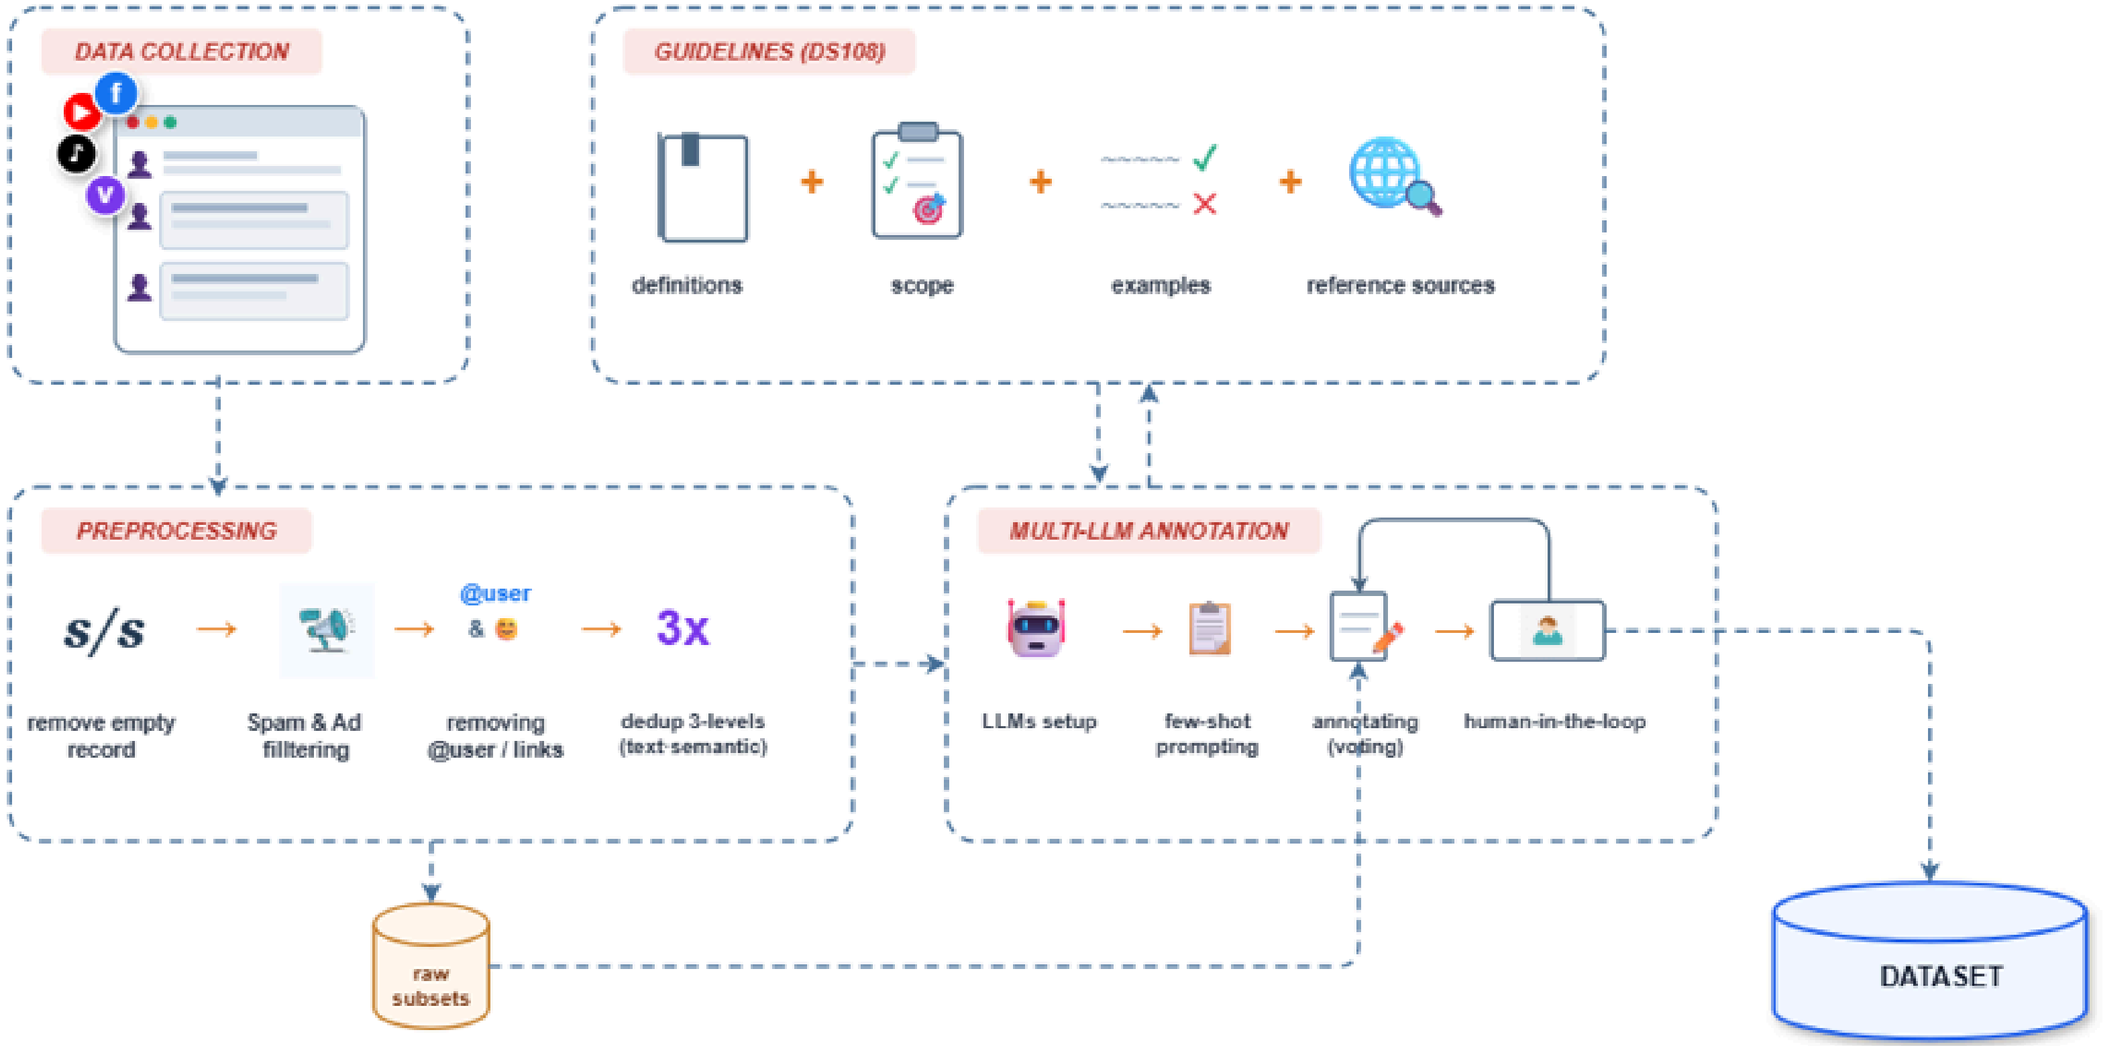
Tiêu chí	TOXIC (Độc hại)	NON-TOXIC (Bình thường / Trung tính)
Định nghĩa	Các phát ngôn, từ ngữ hoặc bình luận mang tính xúc phạm, thô tục, lăng mạ, đe dọa, phân biệt đối xử, khiếm nhã, thiếu đạo đức hoặc gây tổn thương tâm lý cho người khác, làm cuộc trò chuyện trở nên tiêu cực.	Các phát ngôn, từ ngữ hoặc bình luận không chứa các yếu tố xúc phạm, thô tục, đe dọa hay bất kỳ nội dung nào gây tổn thương tâm lý cho người khác hoặc làm cuộc trò chuyện trở nên tiêu cực.
Ví dụ thực tế minh họa & Phân tích căn cứ	• *"bạn bốn, bốn vãi lèo"* → *Phân tích:* Sử dụng thủ pháp nói lái ("bốn vãi lèo" = "béo vãi l**") nhằm mục đích miệt thị ngoại hình người khác, gây tổn thương tâm lý sâu sắc.	• *"da chủ shop đẹp vaizzzz"* → *Phân tích:* Khen ngợi làn da của chủ cửa hàng mang hàm ý tích cực; từ "vaizzzz" (= "vãi") chỉ đóng vai trò là khẩu ngữ cảm thán nhấn mạnh mức độ.

2 Bộ dữ liệu

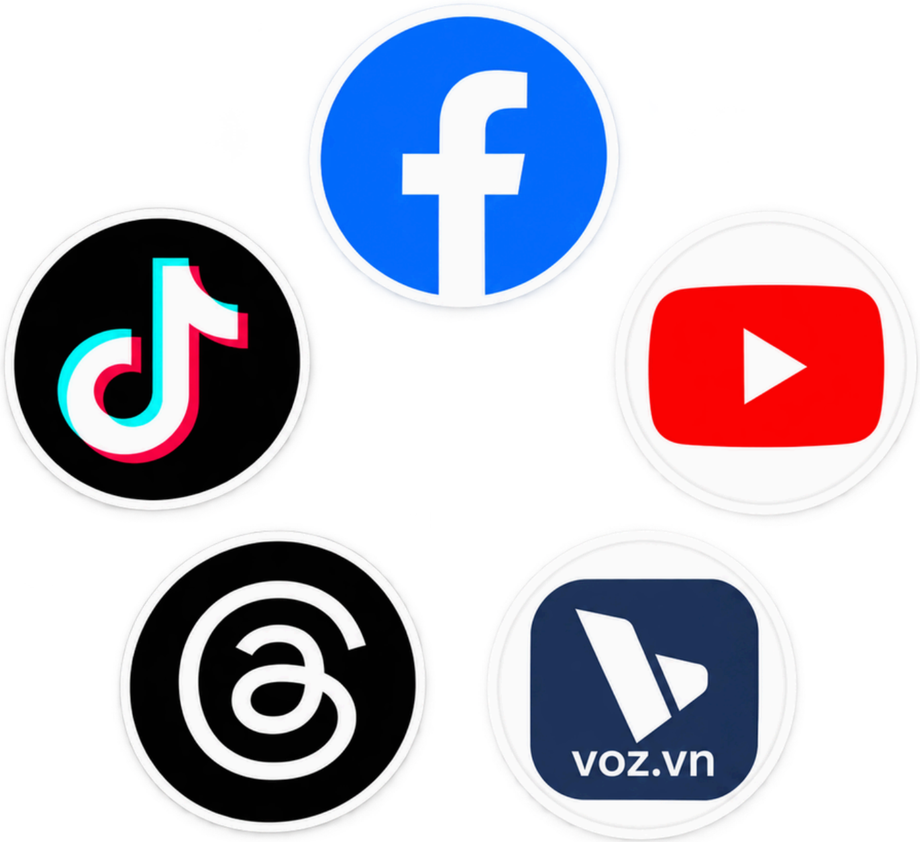
Tiêu chí	EXPLICIT (Trực tiếp)	IMPLICIT (Ẩn ý / Gián tiếp)
Định nghĩa	Những phát ngôn trực tiếp, thể hiện rõ ràng ý định xúc phạm, lăng mạ, kích động thù hận, chửi bới hoặc định kiến đối với cá nhân hay nhóm người.	Những phát ngôn thể hiện sự tấn công ẩn ý, tinh vi, chứa hành vi công kích ngầm như định kiến vi mô, mỉa mai, châm biếm, khen ngược, ẩn dụ hoặc khuôn mẫu hóa.
Ví dụ thực tế minh họa & Phân tích căn cứ	• *"Bọn parky bẩn thỉu cút về chuồng đi* 😡*"* → *Phân tích:* Tấn công và phân biệt vùng miền trực diện bằng từ ngữ miệt thị và xua đuổi gay gắt.	• *"Parky ăn cá rô cây"* → *Phân tích:* Dù có vẻ như một câu nói đùa, cụm từ "Parky" kết hợp từ lóng ẩn ý "cá rô cây" là thành ngữ mạng miệt thị người miền Bắc nghèo khó, chứa định kiến vùng miền sâu sắc.

2 Bộ dữ liệu

Quy trình tổng thể



2 Bộ dữ liệu



- **Facebook**: Không gian tương tác đa thế hệ. Bao quát các chủ đề đời sống, tin tức và tranh luận xã hội.
- **TikTok**: Môi trường video ngắn . Mật độ cao tiếng lóng thế hệ mới, teencode và bình luận theo trào lưu.
- **Threads**: Nền tảng của giới trẻ. Nhiều phát ngôn châm biếm, hoán dụ văn hóa và bắt trend nhanh.
- **YouTube**: Phản hồi đa chiều dưới video . Bình luận dài, lập luận phản biện hoặc công kích cá nhân.
- **Voz Forum:** Đậm đặc tiếng lóng forum, phong cách tranh luận gay gắt và mỉa mai ngầm.

63.697 bình luận

2 Bộ dữ liệu

YouTube

Sử dụng **Data API v3** để trích xuất dữ liệu có cấu trúc (bình luận, tương tác, cha-con). Đảm bảo tính chính xác, tuân thủ chính sách và tối ưu chi phí tài nguyên.

Social Media

Dùng nền tảng **Apify** quét bài viết theo từ khóa/URL. Giải pháp giúp vượt rào cản chống bot hiệu quả để thu thập các chủ đề xã hội nóng trên FB, TikTok & Threads.

VOZ Forum

Sử dụng **Playwright** cào dữ liệu trực tiếp tại các chuyên mục thảo luận nóng. Bóc tách chuẩn xác nội dung, các đoạn trích dẫn và định danh tác giả.

2 Bộ dữ liệu

Quy trình tiền xử lý văn bản 4 bước:

Bước 1: Loại bỏ mã HTML, URL, email .

```
Gửi qua abc@example.com nhé  →  Gửi qua nhé
Liên hệ 0900000000 để mua    →  Liên hệ để mua
Sản phẩm tốt #review #sale   →  Sản phẩm tốt
```

Bước 2: Xóa thông tin định danh cá nhân (thẻ tag người dùng).

"Sản phẩm này thiết kế đẹp quá, cảm ơn @nguyen_van_a đã review chi tiết nhé! 👍 "

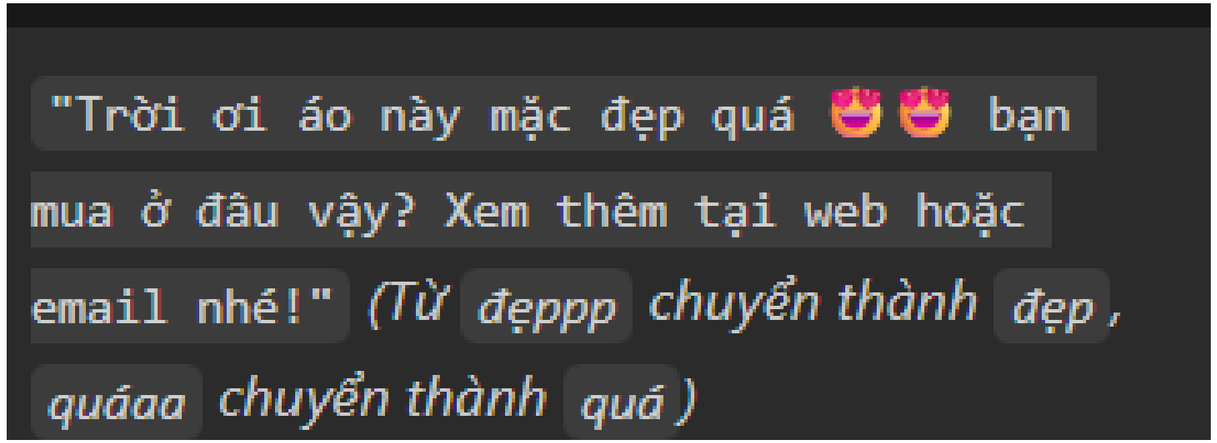
"Sản phẩm này thiết kế đẹp quá, cảm ơn đã review chi tiết nhé! 👍 "

2 Bộ dữ liệu

Quy trình tiền xử lý văn bản 4 bước:

Bước 3: Xóa các dòng trống .

Bước 4: Rút gọn ký tự lặp cố ý ("đẹppp quáaa" → "đẹp quá").



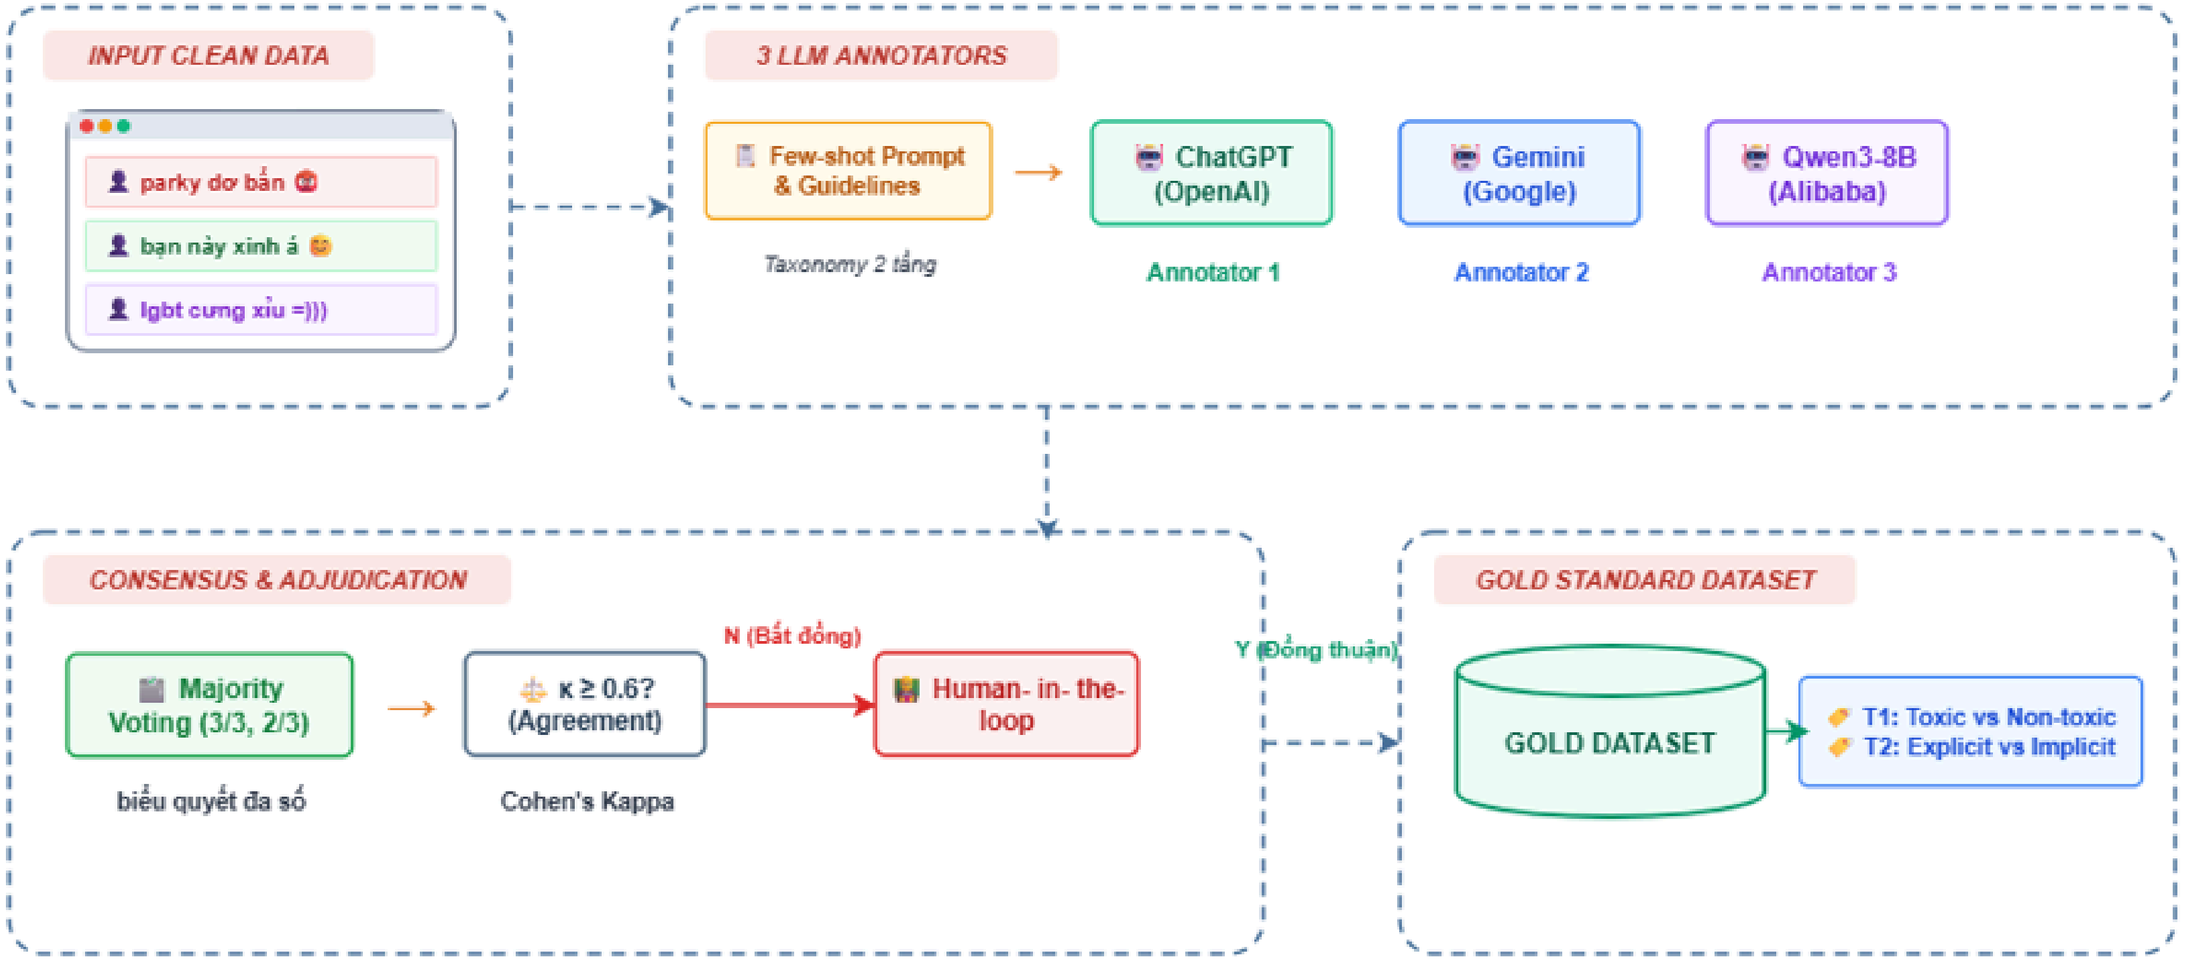
2 Bộ dữ liệu

Cấp 1 — Trùng lặp chính xác : Loại bỏ spam sao chép nguyên văn.
Cấp 2 — Trùng lặp ngữ nghĩa sâu (Sentence-BERT Cosine ≥0,90): Loại bỏ các câu khác chữ nhưng cùng ý nghĩa,

Sợ quá	Sợ quá sợ quá
Liệu kèo châu gác bếp sảy ra k b?	Kèo châu gác bếp liệu sảy ra k b?
Trai bắc đây ạ	Trai bắc
Ngon quá	Ngon rồi
Tào lao	Tào lao quá
Titanic với bốp	Titanic bốp

2 Bộ dữ liệu

QUY TRÌNH DÁN NHÃN



2 Bộ dữ liệu

ĐÁNH GIÁ ĐỘ ĐỒNG THUẬN (FLEISS' KAPPA)

Quy mô toàn bộ tập (*N*)	Số mô hình (*n*)	Tỷ lệ đồng thuận 3/3	Độ đồng thuận quan sát ($\bar{P}$)	Kỳ vọng ngẫu nhiên ($\bar{Pe}$)	Hệ số Fleiss' Kappa	Đánh giá học thuật
48.670	3	**82,72%** (40.260 mẫu)	**88,48%**	**77,28%**	0,4931	**Moderate Agreement** (Đồng thuận tốt)

Fleiss's Kappa: $\kappa = \frac{\overline{\Pr(A)} - \overline{\Pr(e)}}{1 - \overline{\Pr(e)}}$

2 Bộ dữ liệu

ĐẶC TRƯNG THỐNG KÊ

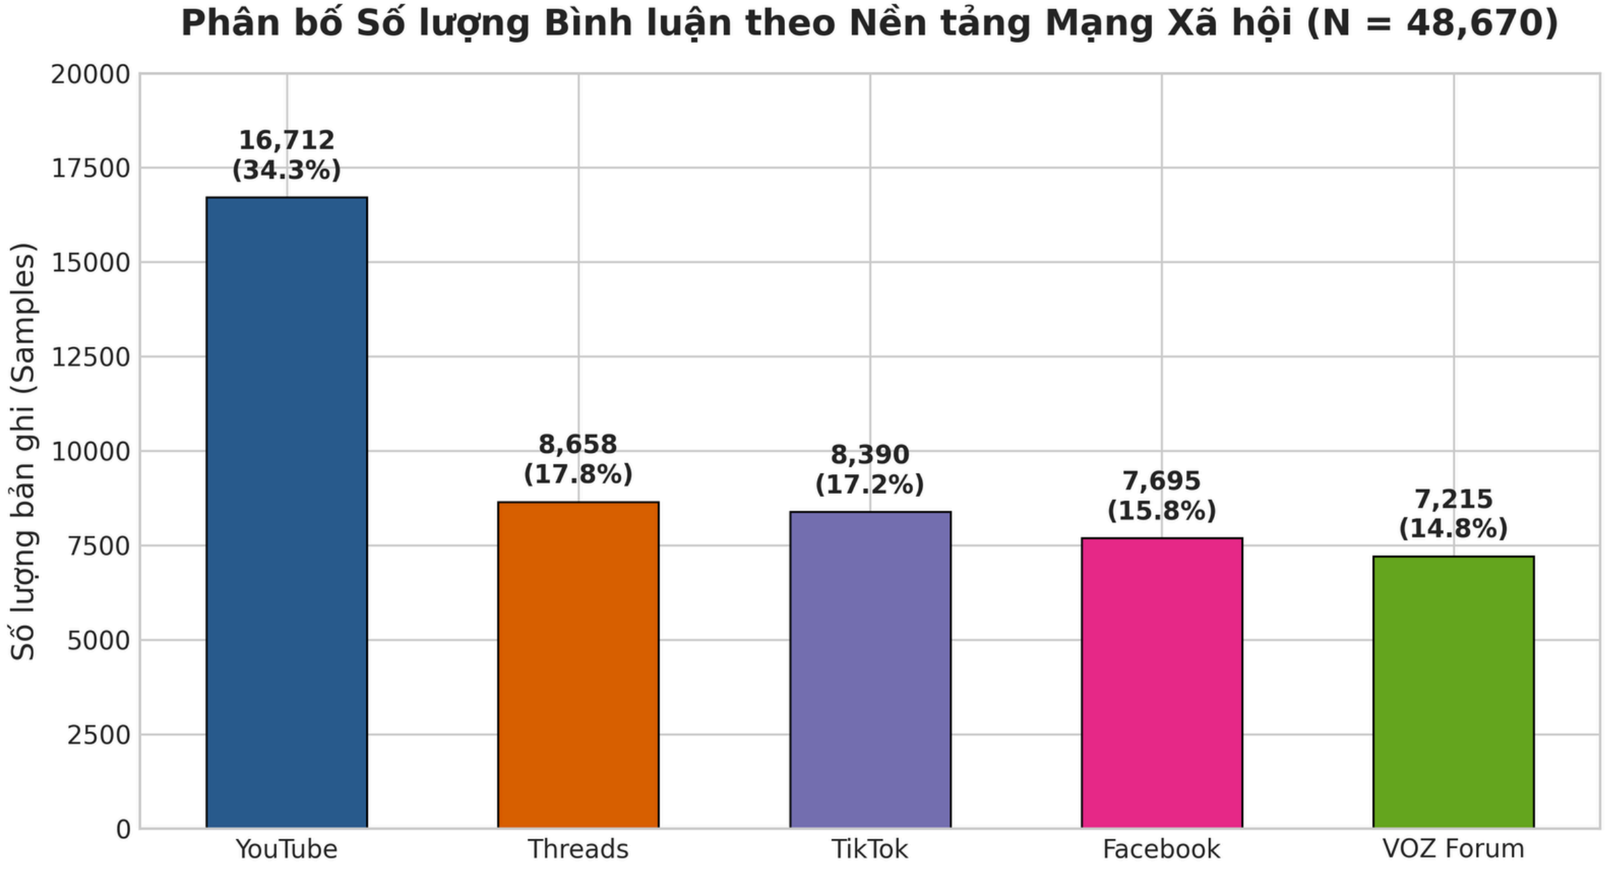
Thống kê phân chia tập dữ liệu:

Tổng số mẫu: 48.670 bình luận.

Train - 80%: 38.936 mẫu.

Dev - 10%: 4.867 mẫu.

Test - 10%: 4.867 mẫu.



2 Bộ dữ liệu

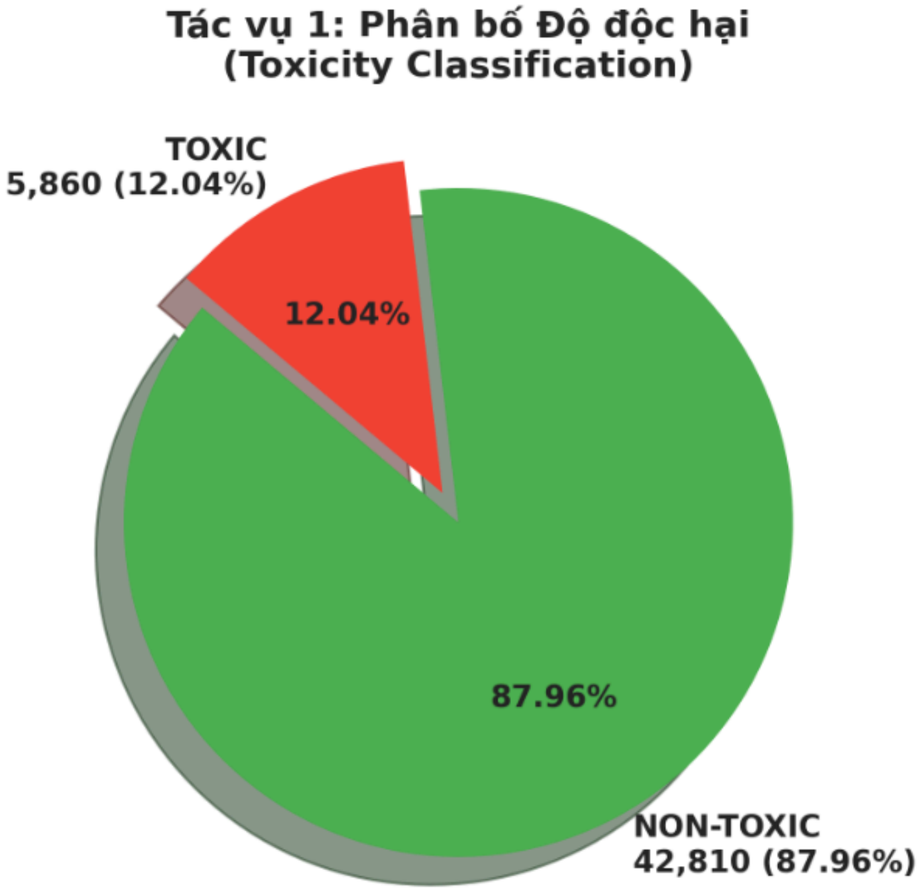
Bộ dữ liệu hoàn thiện bao gồm 5 trường thuộc tính :

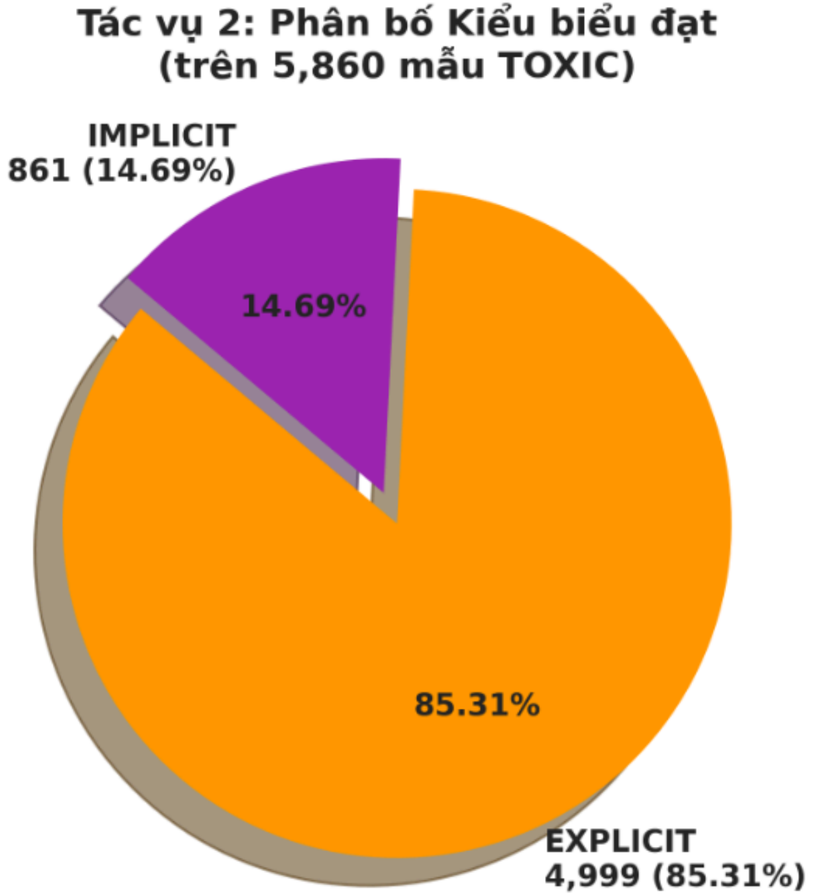
- **row_id** (integer): Mã định danh duy nhất của từng mẫu bình luận .
- **comment** (string): Nội dung văn bản bình luận đã qua toàn bộ quy trình tiền xử lý và chuẩn hóa.
- **toxicity** (string): Nhãn phân loại độc hại ở Tác vụ 1 ("TOXIC" hoặc "NON-TOXIC").
- **expression_type** (string | null): Nhãn kiểu biểu đạt ở Tác vụ 2 ("EXPLICIT" hoặc "IMPLICIT" khi toxicity == "TOXIC"; nhận giá trị null khi toxicity == "NON-TOXIC").
- **evidence** (string): Căn cứ giải thích ngắn gọn lý do phân loại dựa trên nội dung câu văn.

2 Bộ dữ liệu

row_id	comment	toxicity	expression_type	evidence
31734	Nói kỹ hơn thì quân Pháp xây đường tàu trên đất Thanh Hóa. Và người Thanh Hóa đã bán hết lương thực để ăn rau má ở đường tàu, mục đích là để phá đường dây vận chuyển vũ khí cho quân Pháp... Vậy mà ko hiểu sao anh em lấy nó làm câu xúc phạm người Thanh Hóa nữa :P	**NON-TOXIC**		Giải thích về lịch sử vùng miền mang tính xây dựng, hoàn toàn không có lời lẽ công kích vùng miền (dù có chứa từ khóa nhạy cảm "rau má").
44858	Trước khi gọi điện thì độ đã cảnh cáo trên livestream nhiều lần r mà nó có chịu nghe đâu. Thằng ranh có tài nhưng dùng tài k đúng mục đích, phá sv gta, đứa coi tinh thần của cả cộng đồng... dọa là bước cuối cùng buộc làm vì nó là cách nhanh.	**NON-TOXIC**		Tranh luận và giải thích hành động của một streamer (Độ), phê phán hành vi phá game nhưng tập trung vào sự việc chứ không miệt thị con người.
36948	Em anh độ có khác =))	**NON-TOXIC**		Câu cảm thán/trêu đùa bình thường.
26902	Sau bao nhiêu vụ mà vozer vẫn bị truyền thông dắt mũi như chó vậy? [...] Ngay sau hôm đăng quang thì phát biểu bạn trai cần phấn đấu. Ngày hôm sau thì phát biểu tôi thành hoa hậu trong lúc bạn bè mải uống trà sữa. Tất cả là kịch bản setup.	**TOXIC**	**EXPLICIT**	Công kích, lăng mạ trực tiếp người đọc ("bị dắt mũi như chó") và dùng từ ngữ thô thiển khi nhắc về một nhân vật.
1787	M động vào quỹ xoá đói giảm nghèo của nó rồi đấy =))))	**TOXIC**	**IMPLICIT**	Mỉa mai ngầm, ám chỉ việc đụng chạm đến nguồn sống/lợi ích của ai đó bằng cụm từ ví von "quỹ xóa đói giảm nghèo" nhằm mục đích hạ thấp họ.

2 Bộ dữ liệu


Tác vụ 1: Phân bố Độ độc hại
(Toxicity Classification)
TOXIC
5,860 (12.04%)
12.04%
87.96%
NON-TOXIC
42,810 (87.96%)


Tác vụ 2: Phân bố Kiểu biểu đạt
(trên 5,860 mẫu TOXIC)
IMPLICIT
861 (14.69%)
14.69%
85.31%
EXPLICIT
4,999 (85.31%)

2 Bộ dữ liệu

Nhóm dữ liệu	Đơn vị đo	Số lượng mẫu (N)	Mean (μ)	Median ($p50$)	Std (σ)	Min	Q1 (25%)	Q3 (75%)	Max
Toàn bộ Dataset	Số từ (Words)	48.670	**19,38**	**11,0**	24,30	1	6,0	22,0	200
Toàn bộ Dataset	Số ký tự (Chars)	48.670	**81,64**	**45,0**	105,01	1	23,0	94,0	1.030
NON-TOXIC	Số từ (Words)	42.810	18,25	10,0	23,08	1	5,0	21,0	200
NON-TOXIC	Số ký tự (Chars)	42.810	76,91	43,0	100,04	1	22,0	88,0	1.030
TOXIC	Số từ (Words)	5.860	**27,66**	**17,0**	30,57	1	9,0	34,0	200
TOXIC	Số ký tự (Chars)	5.860	**116,22**	**72,0**	130,85	3	36,0	141,0	902
EXPLICIT	Số từ (Words)	4.999	**28,84**	**18,0**	31,49	1	9,0	36,0	200
EXPLICIT	Số ký tự (Chars)	4.999	**121,19**	**75,0**	134,76	3	37,0	149,0	902
IMPLICIT	Số từ (Words)	861	20,80	13,0	23,42	2	8,0	24,0	194
IMPLICIT	Số ký tự (Chars)	861	87,35	54,0	100,61	6	32,0	99,0	862

Nhận xét: Phân bố độ dài của bình luận mạng xã hội tiếng Việt có dạng lệch phải rõ rệt. Đa số các bình luận (trên 75%) có độ dài dưới 22 từ.

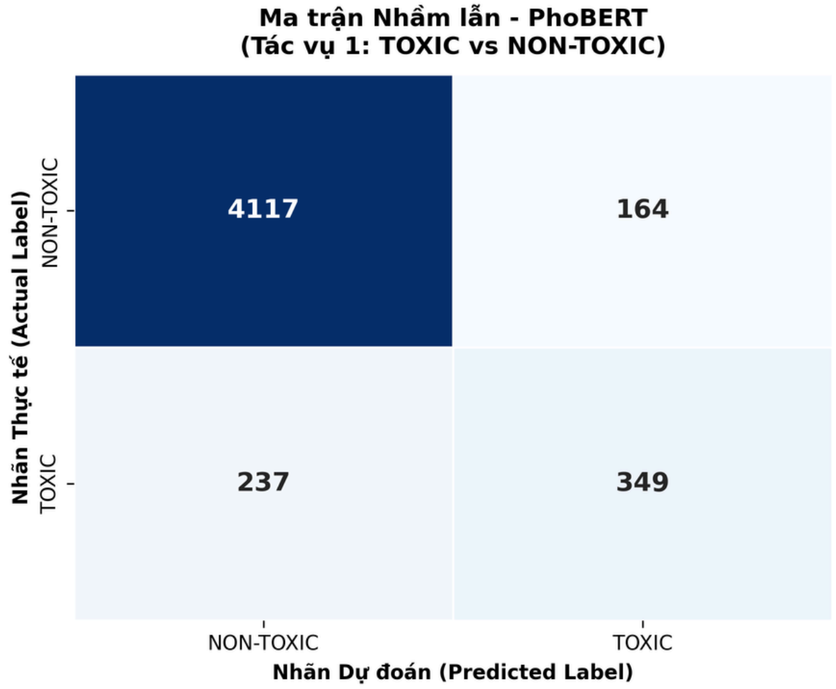
2 Bộ dữ liệu

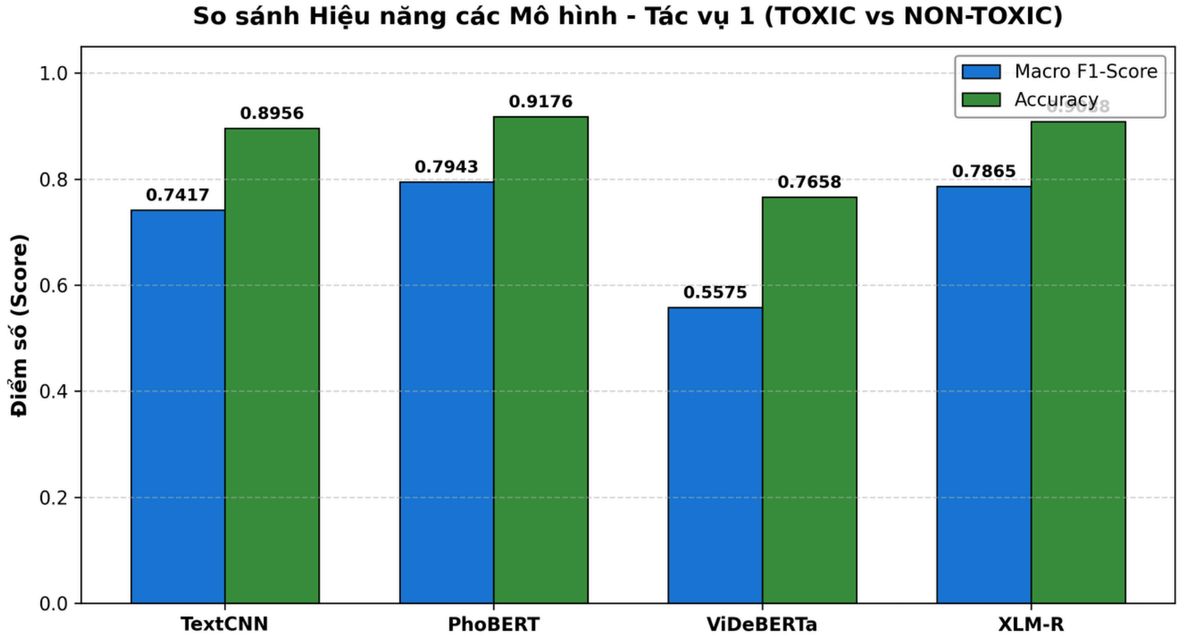

Word Cloud — Các từ xuất hiện phổ biến trong nhóm TOXIC
con
mày
thằng
nó
chúng
ông
bà
tôi
chúng
phải
đéo
đừng
ăn
nói
đi
làm
đến
biết
cái
thì
là
có
không
được
rồi
thì
nhà
bố
mẹ
đàn
bà
chó
đĩ
ngu
dốt
học
hành
tiền
việc
chết
giờ
nước
mặt
đàn
chúng
ta
chúng
dân
nữ
khác
hết
phải
ông
bà
anh
trong
công
năm
thể
tiền
bản
tư
nhất
quyền
trước
chính
thường
tưởng
bắc
đạo
cảm
trai
yêu
sống
chuyện
mất
đầu
tình
tính
toàn
nhân
đứa
đc
nghĩ
ngoài
bao
xong
chắc
cao
chưa
xem
bài
tụi
mồm
nhận
giáo
viên
vẫn
bỏ
chửi
lý
vì
quan
theo
nhau
giới
chơi
độ
tự
nghe
bằng
thứ
kinh
kỳ
gặp
trẻ
tin
gia
nếu
lũ
tốt
chịu
đời
cách
kiểu
gái
đời
chả
vừa
hiểu
tiếng
muốn
ngày
bình
đồng
minh
ấy
tới
mới
nhỉ
số
họ
sự
phụ
vô
sau
thân
câu
em
tạo
xấu
việt
động
tâm
cần
hội
sinh
lúc
văn
chủ
trên

3 Thực nghiệm và mô hình

KẾT QUẢ THỰC NGHIỆM TÁC VỤ 1 — PHÂN LOẠI ĐỘC HẠI

Mô hình	Kiến trúc Nền tảng	Accuracy	Macro Precision	Macro Recall	Macro F1	Weighted F1	PR-AUC (TOXIC)
TextCNN	1D-CNN Baseline (Word Embeddings)	0,8956	0,7544	0,7308	0,7417	0,8931	0,5782
PhoBERT-base-v2	Pretrained RoBERTa (Đơn ngữ Tiếng Việt)	**0,9176**	**0,8129**	0,7786	**0,7943**	**0,9152**	**0,6943**
ViDeBERTa-base	Pretrained DeBERTa (Disentangled Attention)	0,7658	0,5530	0,5782	0,5575	0,7880	0,1888
XLM-RoBERTa-base	Pretrained RoBERTa (Đa ngôn ngữ)	0,9088	0,7841	**0,7891**	0,7865	0,9092	0,6819

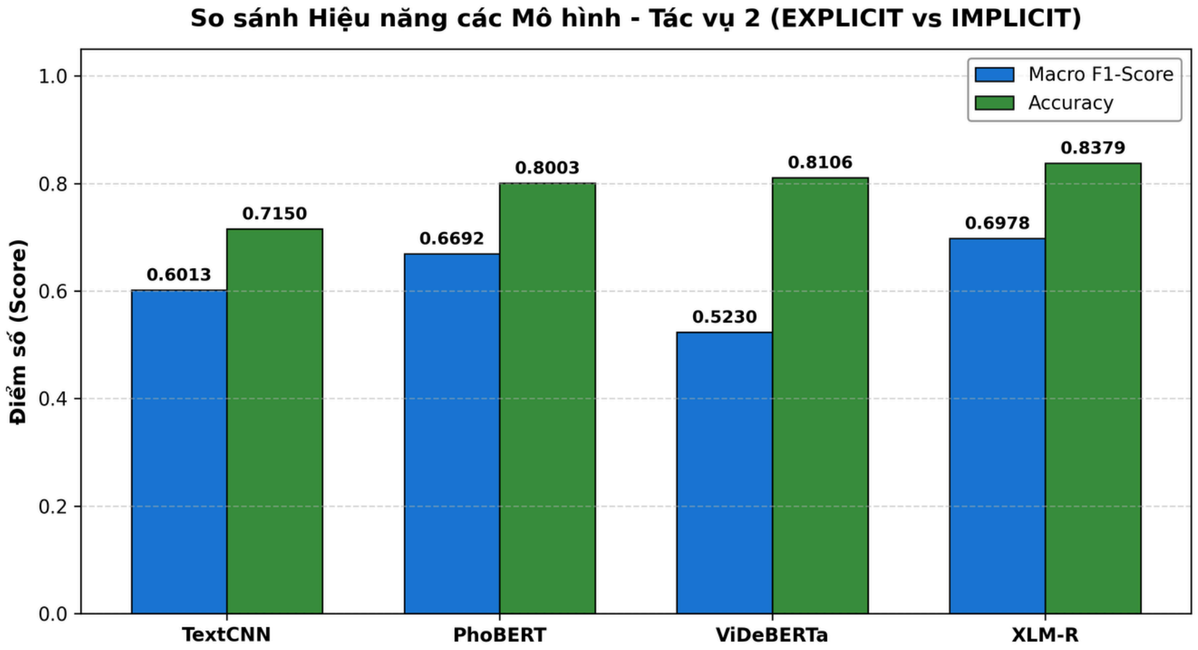


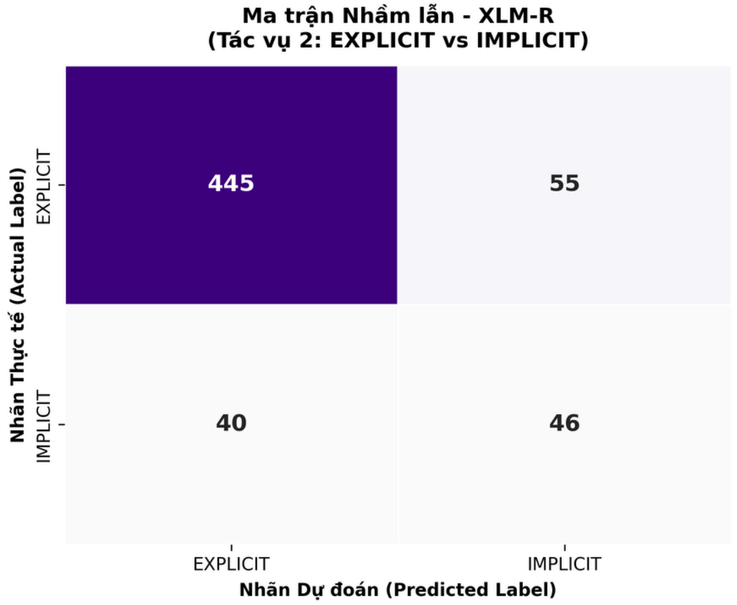


3 Thực nghiệm và mô hình

KẾT QUẢ THỰC NGHIỆM TÁC VỤ — PHÂN LOẠI BIỂU ĐẠT

Mô hình	Kiến trúc Nền tảng	Accuracy	Macro Precision	Macro Recall	Macro F1	Weighted F1	PR-AUC (IMPLICIT)
TextCNN	1D-CNN Baseline (Word Embeddings)	0,7150	0,6004	0,6741	0,6013	0,7517	0,3502
PhoBERT-base-v2	Pretrained RoBERTa (Đơn ngữ Tiếng Việt)	0,8003	0,6513	0,7097	0,6692	0,8163	**0,5016**
ViDeBERTa-base	Pretrained DeBERTa (Disentangled Attention)	0,8106	0,5409	0,5231	0,5230	0,7847	0,2274
XLM-RoBERTa-base	Pretrained RoBERTa (Đa ngôn ngữ)	**0,8379**	**0,6865**	**0,7124**	**0,6978**	**0,8432**	0,4628





3 Thực nghiệm và mô hình

PHÂN TÍCH CÁC YẾU TỐ ẢNH HƯỞNG

1, Ảnh hưởng của Độ dài câu văn:

- Nhóm cực ngắn (<5 từ): Hiệu năng suy giảm do thiếu ngữ cảnh hỗ trợ.
- Nhóm trung bình (5−30 từ): Đạt hiệu năng tối ưu và ổn định nhất (F1>0,80).
- Nhóm dài (>30 từ): TextCNN sụt giảm mạnh do giới hạn cửa sổ tích chập; Transformer duy trì phong độ tốt nhờ Self-Attention toàn cục.

2. Ảnh hưởng của Nhóm Chủ đề Xã hội:

- Chủ đề Vùng miền & Giới tính: Hiệu năng nhận diện cao nhờ từ vựng đặc trưng rõ rệt.
- Chủ đề Tôn giáo & Bệnh tật: Dễ phát sinh lỗi do ranh giới mong manh giữa phản biện giáo lý/chia sẻ y khoa với hành vi miệt thị.

4 HẠN CHẾ, HƯỚNG PHÁT TRIỂN

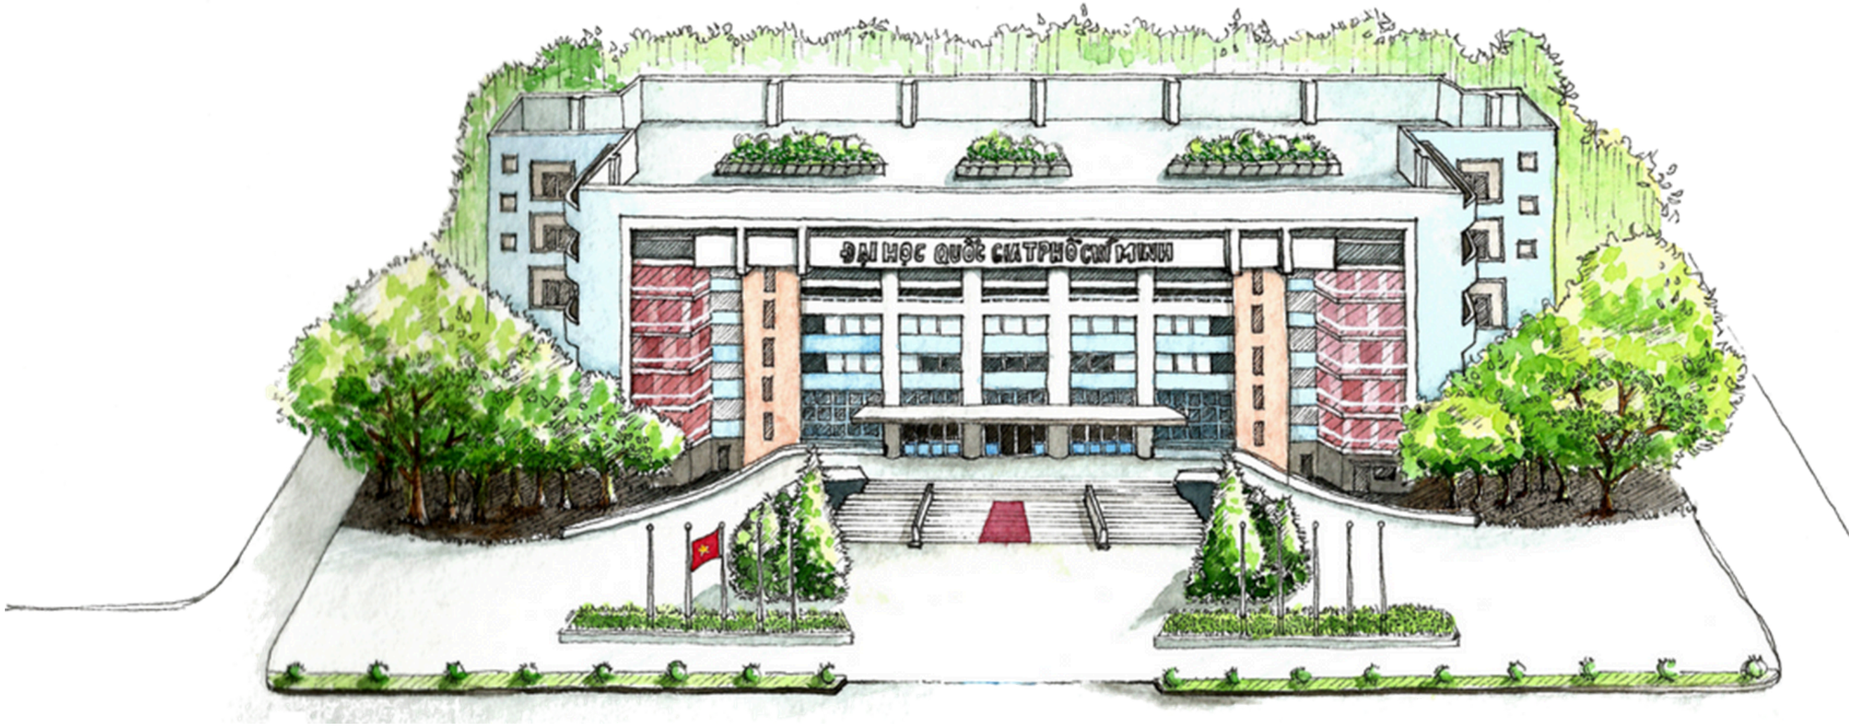
Bốn hướng phát triển tương lai:

1. Mô hình Đa phương thức (Multimodal VLM): Kết hợp hình ảnh meme/video với văn bản.

2. Cơ chế Học liên tục (Continual Learning): Tự động cập nhật từ điển tiếng lóng động.

3. Trí tuệ nhân tạo có thể giải thích (Explainable AI): Tự động trích xuất vùng bằng chứng độc hại.

4. Nén nhẹ mô hình (Model Quantization): Phục vụ triển khai trên Edge Server kiểm duyệt thời gian thực.



Cảm ơn thầy và các bạn

ROLE

Bạn là annotator cho bình luận tiếng Việt. Chỉ đọc Comment được cung cấp. Đọc toàn câu, không dò từ khóa riêng lẻ, không suy diễn ngữ cảnh ngoài Comment và không tự tạo nhãn mới.

LABELS

- TOXIC: Có xúc phạm, lăng mạ, đe dọa, quấy rối, hạ nhục, phân biệt, chế giễu hoặc công kích gây tổn thương/làm cuộc trò chuyện tiêu cực.
- NON-TOXIC: Tích cực, trung tính, hỏi đáp hoặc phản biện ý tưởng/hành vi/sự việc mà không công kích người hay nhóm người.
- EXPLICIT: Nội dung độc hại trực tiếp, rõ ràng trên bề mặt câu chữ.
- IMPLICIT: Nội dung độc hại qua mỉa mai, ám chỉ, hàm ý, khen ngược hoặc khuôn mẫu hóa.

DECISION RULES

1. Không có căn cứ công kích → toxicity=NON-TOXIC.
2. Có căn cứ công kích → toxicity=TOXIC.
3. Với TOXIC: Trực tiếp/rõ ràng → expression_type=EXPLICIT; Ẩn ý/mỉa mai/hàm ý → expression_type=IMPLICIT.
4. Từ tục không tự động là TOXIC; phải xét chức năng trong toàn bộ câu ngữ cảnh.
5. Phê bình ý tưởng, chính sách hoặc sự việc không phải công kích con người.
6. Trích dẫn để phản bác/lên án rõ ràng → NON-TOXIC; nếu dùng để công kích → đánh giá theo nội dung độc hại.
7. Emoji, teencode, tiếng Việt không dấu và từ lóng phải được đọc cùng toàn câu.
8. Nếu thiếu căn cứ hoặc có nhiều cách hiểu hợp lý → tất cả trường nhãn là null, needs_review=true và ghi rõ review_reason.

OUTPUT RULES

- NON-TOXIC → expression_type=null.
- TOXIC → expression_type=EXPLICIT hoặc IMPLICIT.
- Chỉ trả về một JSON object hợp lệ duy nhất, không Markdown, không giải thích ngoài JSON.

FEW-SHOT EXAMPLES
Comment: "Đm phim này cuốn vl, coi đã ghê 😂"
Output: {"toxicity":"NON-TOXIC","expression_type":null,"evidence":"Cảm thán khen ngợi nội dung phim, không công kích ai.","needs_review":false,"review_reason":null}

Comment: "Mày ngu vcl, nói chuyện nghe ngứa tai. Biến mẹ đi."
Output: {"toxicity":"TOXIC","expression_type":"EXPLICIT","evidence":"Chửi bới thô tục và đuổi trực tiếp một cá nhân.","needs_review":false,"review_reason":null}

Comment: "Trình độ đỉnh vl, lần nào làm cũng phá cho bằng được 😌"
Output: {"toxicity":"TOXIC","expression_type":"IMPLICIT","evidence":"Khen ngược mỉa mai nhằm hạ thấp đối phương.","needs_review":false,"review_reason":null}

Comment: "Vãi, hay ghê 🙃"
Output: {"toxicity":null,"expression_type":null,"evidence":"Có thể là khen hoặc mỉa mai; thiếu ngữ cảnh giao tiếp.","needs_review":true,"review_reason":"Không xác định được ý định từ comment đơn lẻ."}

INPUT
Comment: {comment}

OUTPUT JSON SCHEMA
{
 "toxicity": "TOXIC | NON-TOXIC | null",
 "expression_type": "EXPLICIT | IMPLICIT | null",
 "evidence": "một câu ngắn giải thích căn cứ dựa trên comment",
 "needs_review": true | false,
 "review_reason": "null hoặc lý do cần chuyên gia kiểm duyệt"
}