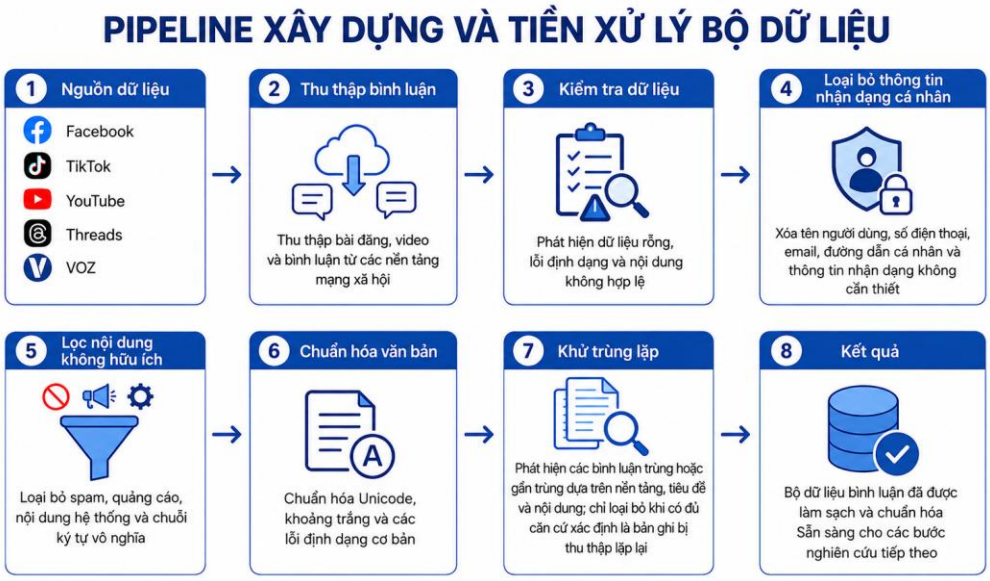
QUY TRÌNH TIỀN XỬ LÝ DỮ LIỆU

Tiền xử lý dữ liệu giúp đưa các bình luận thu thập từ nhiều nền tảng về dạng thống nhất, giảm nhiễu và bảo đảm dữ liệu phù hợp cho các bước phân tích tiếp theo.



Hình 1. Pipeline xây dựng và tiền xử lý bộ dữ liệu

Các bước thực hiện

1. **Kiểm tra dữ liệu đầu vào:** xác định bản ghi rỗng, thiếu nội dung hoặc sai định dạng.
2. **Loại bỏ thông tin nhận dạng cá nhân:** xóa tên người dùng, số điện thoại, email, đường dẫn cá nhân và các thông tin không cần thiết.
3. **Lọc nội dung không hữu ích:** loại bỏ spam, quảng cáo, nội dung hệ thống và chuỗi ký tự vô nghĩa; không loại bỏ bình luận chỉ vì nội dung ngắn.
4. **Chuẩn hóa văn bản:** chuẩn hóa Unicode, khoảng trắng và các lỗi định dạng cơ bản, đồng thời giữ nguyên cách diễn đạt tự nhiên của người dùng.
5. **Kiểm tra trùng lặp:** phát hiện các bản ghi trùng hoặc gần trùng dựa trên nền tảng, tiêu đề và nội dung sau chuẩn hóa.
6. **Đánh giá và hoàn thiện:** chỉ xóa bản ghi khi có đủ căn cứ cho thấy dữ liệu bị thu thập lặp lại; các bình luận giống nhau nhưng thuộc bài đăng hoặc nền tảng khác vẫn được giữ lại.

Kết quả: bộ dữ liệu bình luận được làm sạch, chuẩn hóa và sẵn sàng cho quá trình phân tích hoặc nghiên cứu tiếp theo.

VÍ DỤ MINH HỌA

Một số ví dụ ngắn dưới đây minh họa cách áp dụng từng bước mà vẫn giữ nguyên ý nghĩa của bình luận.

Bước xử lý	Ví dụ
1. Kiểm tra dữ liệu đầu vào	Các giá trị None, chuỗi rỗng "" hoặc chuỗi chỉ có khoảng trắng " " được loại bỏ.
2. Xóa thông tin nhận dạng	@nam xem video này đi → xem video này đi. Email, số điện thoại và URL cá nhân cũng được xóa khỏi text_clean.
3. Lọc nội dung không hữu ích	"Mua hàng tại www... – liên hệ 090..." có thể bị loại khi khớp luật quảng cáo. Các bình luận ngắn như "tuyệt", "ghét" hoặc "buồn quá" vẫn được giữ vì có ý nghĩa.
4. Chuẩn hóa văn bản	" Phim Này Hay " → "phim này hay". Emoji mang cảm xúc được giữ nguyên, ví dụ: "hay quá 😂".
5. Kiểm tra trùng lặp	@nam xem video này đi và @linh xem video này đi có thể giống nhau sau khi xóa tên; chỉ đánh dấu là ứng viên trùng để review, không xóa tự động.
6. Đánh giá và hoàn thiện	"hay quá 😂" và "hay quá 😔" phải được giữ riêng vì emoji có thể làm thay đổi sắc thái. Chỉ xóa khi có ID nguồn hoặc kiểm tra thủ công xác nhận dữ liệu bị thu thập lặp.